

Συγκριτική Μελέτη Συνελικτικών Νευρωνικών Δικτύων για Αναγνώριση Φαγητού και Εκτίμηση Θερμίδων στο Food-11 Dataset



**Εμμανουήλ
Κουργιαντάκης
(me25020)**

manoliskourgiandakis@gmail.com



**Δήμητρα
Συκερίδη
(me25036)**

dsikeridi@gmail.com



**Μαρία Ελένη
Κασιούμη
(me25016)**

mar.kasioum@gmail.com

I. ΕΙΣΑΓΩΓΗ

Το Πρόβλημα



Κίνητρο:

Η αυτοματοποιημένη διατροφική αξιολόγηση είναι κρίσιμη για την παρακολούθηση της παχυσαρκίας και των σχετικών νοσημάτων.

Συναφείς Εργασίες - Baselines

- **Singla et al. [4]:** 
83,6% Accuracy
(GoogLeNet). Το σύνηθες σημείο αναφοράς.
- **Sarac & Ozyilmaz [5]:** 
88,08% Accuracy
(AlexNet/VGG16 features + SVM).
- **Yang [6]:** 
~88-90% Accuracy
(Transfer learning & Ensembles).

Το Διττό Πρόβλημα: Αναγνώριση και Διατροφική Αξιολόγηση

Αναγνώριση (Food Recognition)



Η Πρόκληση: Εξαγωγή χαρακτηριστικών παρά την τεράστια οπτική ποικιλομορφία (διαφορετικές μέθοδοι παρασκευής, φωτισμός).

Η Λύση: Μετάβαση από **hand-crafted features** σε **Συνελικτικά Νευρωνικά Δίκτυα (CNNs)** για ιεραρχικές αναπαραστάσεις.

Εκτίμηση Θερμίδων (Calorie Estimation)




Η Πρόκληση: Απαιτεί ταυτόχρονη γνώση του είδους τροφίμου ΚΑΙ του μεγέθους της μερίδας.

Η Λύση: Ενσωμάτωση γεωμετρικών αντικειμένων αναφοράς ή πιθανοτικών προσεγγίσεων βασισμένων στο USDA.

Ι. ΕΙΣΑΓΩΓΗ

Συνεισφορά της Παρούσας Εργασίας

1



Custom Baseline

Σχεδιασμός και εκπαίδευση από το μηδέν (from scratch) ενός custom CNN για αξιολόγηση του transfer learning.

2



2-Phase Transfer Learning

Εξαγωγή χαρακτηριστικών ("παγωμένα" βάρη) και πλήρες fine-tuning σε 3 μοντέλα (ResNet50, MobileNetV2, EfficientNet-B0).

3



Weighted Loss

Ενσωμάτωση σταθμισμένης συνάρτησης κόστους και στοχευμένου data augmentation για αντιμετώπιση ανισορροπίας κλάσεων.

4



Εκτίμηση Θερμίδων

Δύο συμπληρωματικές προσεγγίσεις (Πιθανοτική Top-K & Γεωμετρική με reference object).

5



Σύγκριση

Ανταγωνιστική απόδοση έναντι της υπάρχουσας βιβλιογραφίας.

Το Σύνολο Δεδομένων Food-11

16.643

Συνολικές Εικόνες

11


Κλάσεις Φαγητού

59% / 21% / 20%

(Train/Validation/Test Split)



Κατανομή δειγμάτων ανά κλάση και split



II. ΜΕΘΟΔΟΛΟΓΙΑ

Προ-επεξεργασία Δεδομένων & Data Augmentation

Standard Input

Προσαρμογή σε 224×224 pixels και κανονικοποίηση με στατιστικά ImageNet.

Κρίσιμο: Η παράλειψη προκαλεί πτώση 15-20% στην απόδοση.

Training Set Augmentation



RandomResizedCrop (Scale 0.8–1.0):
Προσομοίωση διαφορετικών zoom/γωνιών.



RandomHorizontalFlip (p=0.5): Φυσική συμμετρία πιάτων.



RandomRotation ($\pm 15^\circ$):
Κλίσεις κάμερας.




ColorJitter:
Προσαρμογή φωτισμού.



ΔΕΝ εφαρμόστηκε κάθετος αντικατοπτρισμός (vertical flip) λόγω του αυστηρού προσανατολισμού "πάνω/κάτω" των πιάτων.

Εξισορρόπηση μάθησης: Σταθμισμένη συνάρτηση κόστους για την αντιμετώπιση του έντονου class imbalance (5,36×).


Το Food-11 παρουσιάζει έντονη ανισορροπία: Η κατηγορία Dessert έχει 1.500 δείγματα, ενώ το Rice μόλις 280. Εφαρμόστηκε Weighted Cross-Entropy Loss για να αποφευχθεί η μεροληψία.



Rice
(280 samples)



Dessert
(1.500 samples)



Τύπος βάρους κλάσης: $w_i = \frac{N_{total}}{N_{classes} \times N_i}$
(όπου $N_{total} = 9.866$ training samples, $N_{classes} = 11$)

Αυτή η προσέγγιση επιβάλλει στο δίκτυο να δώσει προσοχή στις σπάνιες κατηγορίες, εξασφαλίζοντας υψηλό F1-score ανεξαρτήτως πλήθους.

II. ΜΕΘΟΔΟΛΟΓΙΑ

Συγκριτική Ανάλυση Αρχιτεκτονικών CNN

Custom CNN (Baseline)	MobileNetV2	EfficientNet-B0	ResNet50
 Σχεδιασμός	 Σχεδιασμός	 Σχεδιασμός	 Σχεδιασμός
Εκπαίδευση from scratch (4 conv blocks, Global Average Pooling).	Αποδοτικότητα σε φορητές συσκευές (Depthwise separable convolutions, inverted residuals).	NAS (Neural Architecture Search), ισορροπημένη κλιμάκωση βάθους/πλάτους/ανάλυσης.	Υπολειμματικές συνδέσεις (skip connections) για αποφυγή vanishing gradient. 50 επίπεδα.
 Παράμετροι	 Παράμετροι	 Παράμετροι	 Παράμετροι
~1,21M	~2,24M	~4,02M	~23,5M (Προεκπαιδευμένο στο ImageNet V2)

II. ΜΕΘΟΔΟΛΟΓΙΑ

Στρατηγική Μεταφοράς Μάθησης 2 Φάσεων

Φάση 1: Frozen Feature Extraction



- **Διάρκεια:** 5 εποχές (Epochs)
- **Ρυθμίσεις:** Backbone **κλειδωμένο** (**requires_grad = False**). Εκπαίδευση μόνο του νέου ταξινομητή (Learning Rate: 10^{-3}).
- **Στόχος:** Ευθυγράμμιση του νέου head με τα χαρακτηριστικά του ImageNet.

Φάση 2: Full Fine-Tuning



- **Διάρκεια:** 5 επιπλέον εποχές
- **Ρυθμίσεις:** **Discriminative Learning Rates**. Ήπια προσαρμογή κορμού (10^{-5}) και ταχύτερη προσαρμογή ταξινομητή (10^{-4}).
- **Στόχος:** Αποτροπή της "**καταστροφικής λήθης**" (catastrophic forgetting) των αρχικών χαρακτηριστικών.

II. ΜΕΘΟΔΟΛΟΓΙΑ

Διπλή Προσέγγιση Εκτίμησης Θερμίδων

Μέθοδος Α (Top-K Weighted)

Λογική: Πιθανοτική προσέγγιση με χρήση εξόδων softmax ($K=3$) και του πίνακα USDA. Παράγει διάστημα εμπιστοσύνης.


$$kcal_{est} = \sum_{i=1}^K \hat{p}_i \times kcal_{typical}(class_i)$$

Εξίσωση 2

Μέθοδος Β (Γεωμετρική)

Λογική: Μετατροπή pixel σε cm μέσω αντικειμένου αναφοράς (νόμισμα 2€). Ακρίβεια επιπέδου γραμμαρίου.


$$V = S \times H \times \beta \rightarrow W = V \times \rho \rightarrow kcal = W \times c$$


Εξίσωση 3

S (Επιφάνεια), **H** (Ύψος), **β** (Shape factor),
ρ (Πυκνότητα), **c** (Θερμιδική πυκνότητα).

III. ΑΠΟΤΕΛΕΣΜΑΤΑ


Συγκριτική Απόδοση

ResNet50	Test Acc: 90,29%	Macro F1: 0,9067	Loss: 0,288
EfficientNet-B0	Test Acc: 86,29%	Macro F1: 0,8644	Loss: 0,431
MobileNetV2	Test Acc: 83,75%	Macro F1: 0,8329	Loss: 0,492
CustomCNN	Test Acc: 62,71%	Macro F1: 0,6370	Loss: 1,035




Η αρχιτεκτονική ResNet50 **κυριαρχεί**, καταγράφοντας σχεδόν ταυτόσημη απόδοση σε Accuracy (90,3%) και Macro F1 (90,7%), αποδεικνύοντας **εξαιρετική σταθερότητα** σε όλες τις κλάσεις ανεξαρτήτως μεγέθους.

Το Όριο Αποδοτικότητας (Accuracy vs. Size)



Ανάλυση Απόδοσης Ανά Κατηγορία







Δυσκολότερη Κλάση (Dessert):
CustomCNN: 0,283 -> ResNet50: **0,859 (+57,6 pp)**.

Επιτυχής διαχωρισμός παρά την τεράστια οπτική ποικιλομορφία (κέικ, παγωτό, μακαρόν) και τις οπτικές ομοιότητες με τα γαλακτοκομικά.

Μειονοτική Κλάση (Rice):
ResNet50 επιτυγχάνει F1 = **0,945** παρά το γεγονός ότι η κλάση έχει μόνο 280 δείγματα εκπαίδευσης. Απόδειξη της απόλυτης επιτυχίας της σταθμισμένης συνάρτησης κόστους.

Εξάλειψη Σφαλμάτων Ταξινόμησης



Το Πρόβλημα (CustomCNN):

Λανθασμένη κατηγοριοποίηση της κλάσης **Bread** ως **Fried food** (ποσοστό σφάλματος **20%**) και της κλάσης **Egg** ως **Bread** (**15%**) λόγω έντονων οπτικών ομοιοτήτων.

Η Λύση (ResNet50):

Με τη μετάβαση σε ισχυρότερη αρχιτεκτονική και μεταφορά μάθησης, η κύρια διαγώνιος πυκνώνει εντυπωσιακά (**Accuracy 90,3%**) και τα συγκεκριμένα συστηματικά σφάλματα **εξαλείφονται** σχεδόν ολοκληρωτικά.

Σύγκριση με την Υπάρχουσα Βιβλιογραφία

Πίνακας 2

Μελέτη	Μοντέλο & Ακρίβεια
Singla et al. [4]	GoogLeNet (83,60%)
Sarac & Ozyilmaz [5]	AlexNet+VGG features + SVM (88,08%)
Yang [6]	ResNet50 Ensembles (~88-90%)
Παρούσα Εργασία	ResNet50 + 2-phase Transfer Learning (90,29%)

Οι 4 Πυλώνες της Βελτίωσης

- ✓ Ισχυρότερο δίκτυο κορμού (ResNet50 με ImageNet V2 weights).
- ✓ Transfer learning 2 φάσεων (προστασία από catastrophic forgetting).
- ✓ Weighted Cross-Entropy Loss (εξομάλυνση ανισορροπίας dataset).
- ✓ Στοχευμένα Data Augmentations (προσαρμοσμένα στη γεωμετρία των πιάτων).

III. ΑΠΟΤΕΛΕΣΜΑΤΑ

Πρακτική Αξιολόγηση: Εκτίμηση Θερμίδων

[True: bread Prod: bread (57%) -200 kcal/100g (193-223)] 	[OK] Food Resegnitons Prod: Dany product (33%) -200 kcal/100g (193-223)] 	[True: egg Prod: egg (89%) -125 kcal/100g (120-140)] 	[OK] Belly product Prod: Vegetable Fruit (8%) -166 kcal/100g (193-223)] 	[True: egg Prod: egg (99%) -125 kcal/100g (120-140)] 	[OK] True egg Prod: Fried (20%) -176 kcal/100g (145-140)] 	[True: Seafood Prod: Food (13%) -166 kcal/100g (145-148)] 
[OK] True: freed Prod: Food (27%) -307 kcal/100g (143-223)] 	[OK] True braet Prod: Dairy (89%) -230 kcal/100g (140-400)] 	[OK] True: mast Prod: Fruit (89%) -158 kcal/100g (125-220)] 	[OK] Nene: Noodles Pasta Prod: Vegetabis Fruit (100%) -128 kcal/100g (112-220)] 	[OK] True: egg Prod: egg (80%) -135 kcal/100g (220-140)] 	[OK] True: vegetable fruit Prod: Vegetable fruit (8%) -125 kcal/200g (220-140)] 	[OK] True: mast Prod: Food (89%) -76 kcal/100g (140-152)] 

Calibrated Uncertainty (Μέθοδος Α)




Σε περιπτώσεις υψηλής βεβαιότητας (π.χ. >95%), η τιμή ταυτίζεται με τον μέσο όρο της κλάσης. Σε πολύπλοκες κλάσεις (όπως **Dessert**), το μοντέλο κατανέμει τις πιθανότητες, δημιουργώντας ένα ρεαλιστικό διάστημα [kcal_min, kcal_max].

Συμπληρωματικότητα Μέθοδου Β



Ενώ η Μέθοδος Α (Top-K) είναι ιδανική για "in-the-wild" φωτογραφίες, η Μέθοδος Β προσφέρει επαγγελματική ακρίβεια γραμμαρίου, εφόσον παρέχεται reference object (κέρμα 2€) και segmentation.

Πρακτική Εφαρμογή: Διαδραστικό Υποσύστημα (Real-World Demo)



Το μοντέλο μεταβαίνει επιτυχώς από ένα **ελεγχόμενο** εργαστηριακό περιβάλλον σε **ρεαλιστικές, in-the-wild** συνθήκες

Βασικά Συμπεράσματα

1

Η Αναγκαιότητα του Transfer Learning

Αποδείχθηκε μονόδρομος.
Η μεταφορά μάθησης 2 φάσεων προσέφερε αύξηση **+27,58%** στην ακρίβεια, αποτρέποντας το catastrophic forgetting.

2

Ισορροπία Κόστους - Απόδοσης

Το MobileNetV2 απέδειξε πως η αποδοτική αναγνώριση σε mobile περιβάλλον είναι εφικτή (**83,75% acc με 10x λιγότερες παραμέτρους**).

3

Καταπολέμηση του Data Imbalance

Η χρήση Weighted Cross-Entropy Loss εξασφάλισε κορυφαίες επιδόσεις (**>0,95 F1**) ακόμα και σε κλάσεις με 5 φορές λιγότερα δείγματα εκπαίδευσης.

Περιορισμοί & Μελλοντικές Προοπτικές

Περιορισμοί

- 👉 **Μερική Σύγκλιση:** Το EfficientNet-B0 ίσως απαιτούσε >10 epochs.
- 📐 **Γεωμετρικές Παραδοχές:** Η Μέθοδος B είναι ευαίσθητη στη γωνία λήψης/προοπτική.
- 🕒 **Κλίμακα & Ground Truth:** Το Food-11 είναι σχετικά μικρό (16k) και δεν διαθέτει ground truth θερμίδων για υπολογισμό Mean Absolute Error.

Μελλοντικές Κατευθύνσεις

- 🔥 **Κλιμάκωση (Scaling):** Μετάβαση στο Food-101 (101k εικόνες) ή AI4Food (558k εικόνες).
- 🔪 **Αυτοματοποίηση (Segmentation):** Ενσωμάτωση Mask R-CNN/U-Net για εξαγωγή μερίδας χωρίς αντικείμενο αναφοράς.
- ⚙️ **Νέες Αρχιτεκτονικές:** Αξιολόγηση Vision Transformers (ViT).
- 📱 **Mobile Deployment:** Κβαντισμένα μοντέλα (INT8 MobileNet) για native iOS/Android εφαρμογές.