

Συγκριτική Μελέτη Συνελικτικών Νευρωνικών Δικτύων για Αναγνώριση Φαγητού και Εκτίμηση Θερμίδων στο Food-11 Dataset

Εμμανουήλ Κουργιαντάκης (me25020)
Τμήμα Ψηφιακών Συστημάτων
ΠΙΜΣ Πληροφοριακά Συστήματα
& Υπηρεσίες, Πανεπιστήμιο Πειραιά.
Αθήνα, Ελλάδα
manoliskourgandakis@gmail.com

Δήμητρα Συκερίδη (me25036)
Τμήμα Ψηφιακών Συστημάτων
ΠΙΜΣ Πληροφοριακά Συστήματα
& Υπηρεσίες, Πανεπιστήμιο Πειραιά.
Αθήνα, Ελλάδα
dsikeridi@gmail.com

Μαρία Ελένη Κασιούμη (me25016)
Τμήμα Ψηφιακών Συστημάτων
ΠΙΜΣ Πληροφοριακά Συστήματα
& Υπηρεσίες, Πανεπιστήμιο Πειραιά.
Αθήνα, Ελλάδα
mar.kasioum@gmail.com

Περίληψη— Στην παρούσα εργασία πραγματοποιείται συγκριτική μελέτη τεσσάρων αρχιτεκτονικών Συνελικτικών Νευρωνικών Δικτύων (CNN) για την αναγνώριση εικόνων φαγητού στο dataset Food-11. Συγκρίνεται ένα custom CNN εκπαιδευμένο από το μηδέν με τρία προ-εκπαιδευμένα μοντέλα (ResNet50, MobileNetV2, EfficientNet-B0) μέσω μεθοδολογίας transfer learning δύο φάσεων (frozen feature extraction + full fine-tuning με discriminative learning rates). Εφαρμόζεται σταθμισμένη συνάρτηση κόστους για αντιμετώπιση της ανισορροπίας κλάσεων (imbalance ratio 5,36×) και τεχνικές data augmentation. Τα πειραματικά αποτελέσματα δείχνουν ότι το ResNet50 πετυχαίνει την υψηλότερη ακρίβεια (test accuracy = 90,29%, macro F1 = 0,907), ξεπερνώντας το CustomCNN baseline κατά 27,58 ποσοστιαίες μονάδες. Το MobileNetV2, παρά τις 10× λιγότερες παραμέτρους από το ResNet50, πετυχαίνει αξιόλογο 83,75% accuracy, με πολύ καλή σχέση ακρίβειας και αποδοτικότητας. Επιπλέον, παρουσιάζονται δύο συμπληρωματικές μεθοδολογίες εκτίμησης θερμίδων: (α) πιθανοτική προσέγγιση top-K weighted με χρήση πίνακα αναφοράς USDA και (β) γεωμετρική προσέγγιση με reference object (νόμισμα 2€) για μετατροπή pixel-to-cm. Τα αποτελέσματα είναι συγκρίσιμα με αντίστοιχες μελέτες της βιβλιογραφίας στο ίδιο dataset.

Λέξεις Κλειδιά— Βαθιά Μάθηση, Συνελικτικά Νευρωνικά Δίκτυα, Αναγνώριση Φαγητού, Εκτίμηση Θερμίδων, Food-11, ResNet50, MobileNetV2, EfficientNet.

I. ΕΙΣΑΓΩΓΗ

Η αυτόματη αναγνώριση τροφίμων από εικόνες (food image recognition) αποτελεί ένα σημαντικό πρόβλημα στον τομέα της υπολογιστικής όρασης, με πλήθος πρακτικών εφαρμογών. Οι εφαρμογές αυτές εκτείνονται από την αυτοματοποιημένη διατροφική αξιολόγηση (dietary assessment) και την παρακολούθηση της θερμιδικής πρόσληψης [1], έως τη δημιουργία εργαλείων υποστήριξης για άτομα με διατροφικές διαταραχές, ασθενείς με διαβήτη ή περιπτώσεις που χρήζουν ιατρικής επίβλεψης. Δεδομένης της παγκόσμιας αύξησης της παχυσαρκίας και των σχετικών νοσημάτων, η ανάπτυξη τέτοιων ψηφιακών εργαλείων καθίσταται ιδιαίτερα αναγκαία.

Η πρόοδος που σημειώνεται τα τελευταία χρόνια στη Βαθιά Μάθηση και ειδικότερα στα Συνελικτικά Νευρωνικά Δίκτυα (CNN) [2], έχει αλλάξει ριζικά τον τρόπο προσέγγισης του συγκεκριμένου προβλήματος. Σε αντίθεση με

παλαιότερες μεθόδους, όπου τα χαρακτηριστικά εξάγονταν χειροκίνητα (hand-crafted features), τα μοντέλα CNN μπορούν να εξάγουν ιεραρχικές οπτικές αναπαραστάσεις απευθείας από τα ακατέργαστα (raw) δεδομένα. Η ικανότητα αυτή κρίνεται εξαιρετικά χρήσιμη, καθώς η οπτική αναπαράσταση ενός πιάτου μπορεί να διαφέρει σημαντικά λόγω διαφορετικών μεθόδων παρασκευής, τρόπου σερβιρίσματος ή συνθηκών φωτογράφισης.

Πέρα από την απλή αναγνώριση της κατηγορίας του φαγητού, μια σαφώς μεγαλύτερη πρόκληση αποτελεί η εκτίμηση των θερμίδων (calorie estimation). Ενώ η ταξινόμηση των εικόνων αφορά τον προσδιορισμό μιας διακριτής κλάσης, ο υπολογισμός των θερμίδων προϋποθέτει την ταυτόχρονη γνώση τόσο του είδους του τροφίμου όσο και του μεγέθους της μερίδας. Για τον σκοπό αυτό, συνήθως απαιτείται η αξιοποίηση επιπρόσθετων δεδομένων, όπως αντικείμενα αναφοράς μεγέθους (reference objects) ή πληροφορίες βάθους (depth information) [3], ώστε να υπολογιστεί σωστά η κλίμακα της εικόνας.

A. Συναφείς Εργασίες

Στη βιβλιογραφία εντοπίζονται αρκετές προσεγγίσεις για την αναγνώριση εικόνων φαγητού, πολλές από τις οποίες χρησιμοποιούν ως βάση το σύνολο δεδομένων Food-11. Αρχικά, οι δημιουργοί του dataset, Singla et al. [4], αξιοποίησαν ένα προεκπαιδευμένο δίκτυο GoogLeNet, καταγράφοντας ακρίβεια (accuracy) 83,6% κατά την ταξινόμηση στις 11 διαθέσιμες κλάσεις. Η συγκεκριμένη επίδοση χρησιμοποιείται συχνά ως σημείο αναφοράς (baseline) για νεότερες συγκριτικές μελέτες πάνω στο ίδιο dataset.

Μια εναλλακτική προσέγγιση προτάθηκε από τους Sarac και Ozyilmaz [5], οι οποίοι συνδύασαν την εξαγωγή χαρακτηριστικών (deep feature extraction) με έναν ταξινομητή SVM. Πιο συγκεκριμένα, εξήγαγαν τα χαρακτηριστικά από τα επίπεδα fc6 και fc7 προεκπαιδευμένων δικτύων (AlexNet και VGG16) και τα συνένωσαν (feature concatenation), φτάνοντας σε ακρίβεια 88,08%. Η μεθοδολογία αυτή επιβεβαιώνει ότι τα προεκπαιδευμένα χαρακτηριστικά μπορούν να αποδώσουν ικανοποιητικά, ακόμα και απουσία πλήρους fine-tuning (end-to-end) του δικτύου.

Σε πιο πρόσφατη έρευνα, ο Yang [6] συνέκρινε τέσσερις αρχιτεκτονικές (AlexNet, VGG19, MobileNetV2, ResNet50) στο Food-11, εφαρμόζοντας τεχνικές transfer learning και στρατηγικές ensemble. Τα αποτελέσματα έδειξαν ότι ο συνδυασμός πολλαπλών μοντέλων αυξάνει σημαντικά την απόδοση, εύρημα που επαληθεύεται και από ευρύτερες βιβλιογραφικές ανασκοπήσεις [7], οι οποίες τονίζουν τη σημασία της επιλογής τόσο της κατάλληλης αρχιτεκτονικής όσο και της στρατηγικής εκπαίδευσης.

Σχετικά με το πιο σύνθετο πρόβλημα της εκτίμησης θερμίδων, μια από τις πρώτες ολοκληρωμένες προσεγγίσεις παρουσιάστηκε από τους Pouladzadeh et al. [1]. Η μέθοδός τους βασίστηκε στη χρήση του αντίχειρα του χρήστη ως αντικείμενο αναφοράς (reference object) για τον υπολογισμό της κλίμακας της εικόνας, σε συνδυασμό με αλγορίθμους κατάτμησης (graph cut segmentation) και διατροφικούς πίνακες. Σε ένα πιο σύγχρονο πλαίσιο, οι Rodríguez et al. [8] παρουσίασαν τη βάση δεδομένων AI4Food-NutritionDB. Το συγκεκριμένο σύνολο περιλαμβάνει πάνω από 558.000 εικόνες με διατροφική ταξινόμηση πέντε επιπέδων, προσφέροντας πλέον ένα νέο σημείο αναφοράς (benchmark) για την ανάπτυξη αλγορίθμων που απαιτούν εκτενή διατροφικά δεδομένα.

B. Συνεισφορά της Παρούσας Εργασίας

Στην παρούσα εργασία προτείνεται μια ολοκληρωμένη συγκριτική μελέτη τεσσάρων αρχιτεκτονικών CNN στο Food-11 dataset. Οι κύριες συνεισφορές μας συνοψίζονται ως εξής:

(α) Σχεδιάστηκε και εκπαιδεύτηκε από το μηδέν ένα προσαρμοσμένο (custom) CNN, το οποίο λειτουργεί ως μοντέλο βάσης (baseline) για την αξιολόγηση της αποτελεσματικότητας της μεθόδου transfer learning.

(β) Εφαρμόστηκε μεταφορά μάθησης (transfer learning) σε δύο διακριτές φάσεις (εξαγωγή χαρακτηριστικών με "παγωμένα" βάρη και πλήρες fine-tuning με διαφοροποιημένα learning rates). Η μέθοδος δοκιμάστηκε σε τρία προεκπαιδευμένα δίκτυα (ResNet50, MobileNetV2 και EfficientNet-B0), καλύπτοντας έτσι ένα ευρύ φάσμα: από ιδιαίτερα βαθιά μοντέλα υψηλής ακρίβειας, μέχρι ελαφρύτερες αρχιτεκτονικές, κατάλληλες για φορητές συσκευές.

(γ) Για να εξομαλυνθεί η σημαντική ανισορροπία στο πλήθος των δειγμάτων ανά κατηγορία, ενσωματώθηκε μια σταθμισμένη συνάρτηση κόστους (weighted cross-entropy loss), σε συνδυασμό με τεχνικές επαύξησης δεδομένων (data augmentation) προσαρμοσμένες στις ιδιαιτερότητες των εικόνων φαγητού.

(δ) Προτείνονται δύο συμπληρωματικές προσεγγίσεις για τον υπολογισμό των θερμίδων: μια πιθανοτική μέθοδος που αξιοποιεί τις εξόδους softmax του μοντέλου ταξινόμησης, και μια γεωμετρική μέθοδος που υπολογίζει τη θερμιδική αξία με βάση τις φυσικές διαστάσεις του πιάτου, χρησιμοποιώντας ένα αντικείμενο αναφοράς (reference object).

(ε) Τα αποτελέσματα συγκρίνονται με αντίστοιχες μελέτες στη βιβλιογραφία, επιδεικνύοντας ανταγωνιστική απόδοση.

Η δομή του υπόλοιπου άρθρου είναι η εξής: Στην Ενότητα 2 περιγράφεται η προτεινόμενη μεθοδολογία, συμπεριλαμβανομένων των αρχιτεκτονικών μοντέλων και της στρατηγικής εκπαίδευσης. Η Ενότητα 3 παρουσιάζει το dataset, τον πειραματικό σχεδιασμό και αναλύει τα

αποτελέσματα με συγκριτικούς πίνακες και διαγράμματα, καθώς και τη σύγκριση με τη βιβλιογραφία. Τέλος, στην Ενότητα 4 συνοψίζονται τα βασικά συμπεράσματα και αναφέρονται μελλοντικές κατευθύνσεις έρευνας.

II. ΜΕΘΟΔΟΛΟΓΙΑ

A. Επισκόπηση Συστήματος

Το προτεινόμενο σύστημα αποτελείται από δύο διαδοχικά στάδια: (α) έναν CNN ταξινομητή που αναλαμβάνει την κατηγοριοποίηση της εικόνας εισόδου σε μία από τις 11 κατηγορίες φαγητού του Food-11, και (β) ένα module εκτίμησης θερμίδων που αξιοποιεί την έξοδο του classifier για να παράγει εκτίμηση θερμιδικής αξίας. Όλα τα μοντέλα υλοποιήθηκαν σε PyTorch και εκπαιδεύτηκαν σε NVIDIA T4 GPU του Google Colab. Για την εξασφάλιση αναπαραγωγικότητας των αποτελεσμάτων, χρησιμοποιήθηκαν σταθερές τιμές εκκίνησης (fixed random seeds με SEED = 42) και ντετερμινιστικές ρυθμίσεις στη βιβλιοθήκη cuDNN.

B. Προ-επεξεργασία Δεδομένων και Data Augmentation

Αρχικά, όλες οι εικόνες προσαρμόστηκαν σε διαστάσεις 224×224 pixels, μέγεθος που αποτελεί την τυπική είσοδο (standard input) για τα προεκπαιδευμένα μοντέλα του ImageNet. Στη συνέχεια, εφαρμόστηκε κανονικοποίηση βάσει των στατιστικών του ImageNet (μέση τιμή = $[0,485, 0,456, 0,406]$, τυπική απόκλιση = $[0,229, 0,224, 0,225]$). Η διαδικασία αυτή κρίνεται απαραίτητη για τη διασφάλιση της συμβατότητας των δεδομένων εισόδου με τα προεκπαιδευμένα βάρη (pretrained weights) των δικτύων. Η παράλειψή της ενδέχεται να προκαλέσει μείωση της απόδοσης (της τάξης των 15-20 ποσοστιαίων μονάδων), δεδομένου ότι τα εξαγόμενα χαρακτηριστικά έχουν αρχικά εκπαιδευτεί σε δεδομένα με αυτήν ακριβώς τη στατιστική κατανομή.

Προκειμένου να εμπλουτιστεί το σύνολο εκπαίδευσης (training set), αξιοποιήθηκαν τεχνικές επαύξησης δεδομένων (data augmentation), οι οποίες επιλέχθηκαν ειδικά για τα χαρακτηριστικά των φωτογραφιών τροφίμων:

- RandomResizedCrop (scale 0,8–1,0, ratio 0,9–1,1): Για την προσομοίωση διαφορετικών επιπέδων εστίασης (zoom) και γωνιών λήψης.
- RandomHorizontalFlip (p=0,5): Οριζόντιος αντικατοπτρισμός, ο οποίος εκμεταλλεύεται τη φυσική συμμετρία που παρουσιάζουν τα περισσότερα πιάτα.
- RandomRotation ($\pm 15^\circ$): Μικρής κλίμακας περιστροφές, που αναπαριστούν τις φυσιολογικές κλίσεις της κάμερας κατά τη φωτογράφιση.
- ColorJitter (brightness, contrast, saturation=0,2, hue=0,05): Προσαρμογή των χρωματικών ιδιοτήτων για την προσομοίωση διαφορετικών συνθηκών φωτισμού του περιβάλλοντος.
- Αξίζει να σημειωθεί ότι δεν εφαρμόστηκε κάθετος αντικατοπτρισμός (vertical flip), καθώς η πλειονότητα των εικόνων φαγητού διαθέτει αυστηρό προσανατολισμό (σαφής διαχωρισμός «πάνω/κάτω»). Αντίθετα, για τα σύνολα επικύρωσης (validation set) και δοκιμής (test set), πραγματοποιήθηκε αποκλειστικά ντετερμινιστική προσαρμογή μεγέθους και κανονικοποίηση,

προκειμένου η τελική αξιολόγηση των μοντέλων να παραμείνει αυστηρά συνεπής.

C. Αντιμετώπιση Ανισορροπίας Κλάσεων

Το σύνολο δεδομένων Food-11 χαρακτηρίζεται από έντονη ανισορροπία μεταξύ των κλάσεων, με τον λόγο ανισορροπίας (imbalance ratio) να ανέρχεται σε 5,36×. Ενδεικτικά, η κατηγορία Rice περιέχει μόλις 280 training samples έναντι 1.500 της κατηγορίας Dessert (και της Soup). Χωρίς αντιμετώπιση, αυτή η ανισορροπία θα οδηγούσε σε μεροληπτικά μοντέλα που θα ευνοούν τις πλειονοτικές κλάσεις.

Για την αντιμετώπιση αυτής της ανισορροπίας, χρησιμοποιήθηκε σταθμισμένη συνάρτηση κόστους (weighted cross-entropy loss) όπου το βάρος κάθε κλάσης w_i προσδιορίζεται βάσει της αντίστροφης συχνότητας εμφάνισης των δειγμάτων της:

$$w_i = N_{\text{total}} / (N_{\text{classes}} \times N_i) \quad (\text{Εξ. 1})$$

όπου $N_{\text{total}} = 9,866$ είναι το συνολικό πλήθος training samples, $N_{\text{classes}} = 11$ οι κατηγορίες, και N_i τα samples της κάθε κλάσης. Με αυτό τον τρόπο δίνεται μεγαλύτερο βάρος στις μειονοτικές κλάσεις (π.χ. Rice: $w = 3,20$) και μικρότερο στις πλειονοτικές (π.χ. Dessert: $w = 0,60$), εξασφαλίζοντας ισορροπημένη μάθηση.

D. Αρχιτεκτονικές Μοντέλων

Στο πλαίσιο της παρούσας μελέτης, εξετάζονται και συγκρίνονται τέσσερις αρχιτεκτονικές CNN με διαφορετικά χαρακτηριστικά σχεδιασμού:

- **Custom CNN (Baseline):** Το συγκεκριμένο δίκτυο σχεδιάστηκε εξ ολοκλήρου από το μηδέν, προκειμένου να λειτουργήσει ως μοντέλο βάσης (baseline). Η δομή του αποτελείται από τέσσερα διαδοχικά συνελκτικά μπλοκ (convolutional blocks) με 32, 64, 128 και 256 κανάλια αντίστοιχα. Κάθε μπλοκ περιλαμβάνει δύο συνελκτικά επίπεδα (convolutional layers) με φίλτρα διαστάσεων 3×3 , επίπεδα κανονικοποίησης δέσμης (BatchNormalization), συναρτήσεις ενεργοποίησης ReLU και επίπεδα μέγιστης υποδειγματοληνίας (2×2 MaxPooling). Για τη μείωση των διαστάσεων χρησιμοποιήθηκε η τεχνική Global Average Pooling αντί της συμβατικής προσέγγισης (flatten και dense layers), επιτυγχάνοντας έτσι σημαντικό περιορισμό του πλήθους των παραμέτρων. Ο ταξινομητής αποτελείται από ένα πλήρως συνδεδεμένο επίπεδο (fully-connected classifier) με εφαρμογή dropout ($p = 0,5$), ενώ το συνολικό πλήθος των παραμέτρων του μοντέλου ανέρχεται προσεγγιστικά σε 1,21M.
- **ResNet50:** Η αρχιτεκτονική του ResNet50 [9] εισήγαγε την έννοια των υπολειμματικών συνδέσεων (residual ή skip connections), προσφέροντας λύση στο πρόβλημα της εξασθένισης του βαθμωτού (vanishing gradient problem) που παρατηρείται στα βαθιά δίκτυα. Μέσω αυτού του μηχανισμού, αντί κάθε μπλοκ να επιχειρεί τη μάθηση μιας απευθείας συνάρτησης $F(x)$, προσεγγίζει τη μάθηση του υπολοίπου $F(x) + x$. Αυτό επιτρέπει στο δίκτυο να παρακάμπτει επίπεδα που δεν κρίνονται απαραίτητα, μαθαίνοντας την ταυτοτική συνάρτηση (identity function) όταν αυτό είναι βέλτιστο. Το μοντέλο αποτελείται συνολικά

από 50 επίπεδα με bottleneck blocks, ενσωματώνει περίπου 23,5M παραμέτρους, και χρησιμοποιήθηκε προεκπαιδευμένο με τα βάρη ImageNet (V2 weights).

- **MobileNetV2:** Η συγκεκριμένη αρχιτεκτονική αναπτύχθηκε από την Google [10] με βασικό στόχο την αποδοτική εκτέλεση σε φορητές συσκευές (mobile devices) περιορισμένων πόρων. Για τον σκοπό αυτό, αξιοποιούνται depthwise separable convolutions, όπου η παραδοσιακή συνέλιξη διαχωρίζεται σε δύο στάδια (depthwise και pointwise), καθώς και ανάστροφα υπολειμματικά μπλοκ με γραμμικούς περιορισμούς (inverted residuals με linear bottlenecks). Το μοντέλο περιλαμβάνει περίπου 2,24M παραμέτρους, όντας 10 φορές μικρότερο σε μέγεθος συγκριτικά με το ResNet50, διατηρώντας ωστόσο υψηλά επίπεδα απόδοσης.
- **EfficientNet-B0:** Η αρχιτεκτονική αυτή προέκυψε μέσω αυτοματοποιημένης αναζήτησης νευρωνικής δομής (Neural Architecture Search - NAS) από τους Tan & Le [11]. Χαρακτηρίζεται από μια ομοιόμορφη και ισορροπημένη κλιμάκωση τριών βασικών διαστάσεων: του βάθους του δικτύου (depth), του πλάτους των καναλιών (width) και της ανάλυσης της εικόνας εισόδου (resolution). Ενσωματώνοντας περίπου 4,02M παραμέτρους, το EfficientNet-B0 πετυχαίνει αναβαθμισμένη απόδοση σε σχέση με παραδοσιακά CNN αντίστοιχου μεγέθους στο ImageNet.

E. Στρατηγική Μεταφοράς Μάθησης Δύο Φάσεων (Two-Phase Transfer Learning)

Για τα τρία προ-εκπαιδευμένα μοντέλα εφαρμόστηκε μεθοδολογία μεταφοράς μάθησης (transfer learning) δύο φάσεων:

- **Φάση 1: Εξαγωγή Χαρακτηριστικών με Παγωμένα Βάρη (Frozen Feature Extraction).** Στο στάδιο αυτό, οι παράμετροι του δικτύου κορμού (backbone) διατηρήθηκαν σταθερές (παγωμένες με `requires_grad = False`) και η εκπαίδευση επικεντρώθηκε αποκλειστικά στον νέο ταξινομητή (classifier head), ο οποίος αντικατέστησε το τελικό επίπεδο πλήρους σύνδεσης (fully-connected layer) για την πρόβλεψη των 11 κλάσεων. Η συγκεκριμένη φάση είχε διάρκεια 5 εποχών (epochs), με τη χρήση του βελτιστοποιητή Adam, ρυθμό μάθησης (learning rate) 10^{-3} και συντελεστή μείωσης βαρών (weight decay) 10^{-4} . Μέσω αυτής της διαδικασίας, επιτυγχάνεται η ευθυγράμμιση του ταξινομητή με τα προεκπαιδευμένα χαρακτηριστικά του ImageNet για τις ανάγκες των 11 κατηγοριών, χωρίς να αλλοιωθούν οι γενικές οπτικές αναπαραστάσεις που έχουν ήδη αποκτηθεί από τον κορμό του δικτύου.
- **Φάση 2: Πλήρης Μικρορύθμιση (Full Fine-Tuning):** Στη συνέχεια, ξεπαγώθηκαν όλα τα βάρη του μοντέλου και εφαρμόστηκε πλήρης μικρορύθμιση (fine-tuning) για 5 επιπλέον εποχές. Στη φάση αυτή επιστρατεύτηκαν διαφοροποιημένοι ρυθμοί μάθησης (discriminative learning rates), ορίζοντας τιμή 10^{-5} για τον κορμό (backbone), ώστε να διασφαλιστεί μια ήπια προσαρμογή των

προεκπαιδευμένων βαρών και τιμή 10^{-4} για τον ταξινομητή (classifier head), δηλαδή δέκα φορές υψηλότερη. Η συγκεκριμένη στρατηγική αποτρέπει το φαινόμενο της καταστροφικής λήθης (catastrophic forgetting) των αρχικών χαρακτηριστικών του ImageNet, επιτρέποντας παράλληλα την εξειδικευμένη προσαρμογή στο νέο πεδίο δεδομένων (domain-specific adaptation). Αντίθετα, το μοντέλο βάσης (Custom CNN baseline), το οποίο δεν διέθετε προεκπαιδευμένα βάρη, εκπαιδεύτηκε εξ ολοκλήρου από το μηδέν για 25 εποχές με τον βελτιστοποιητή Adam (learning rate = 10^{-3}) και τον χρονοπρογραμματιστή ReduceLROnPlateau (με συντελεστή μείωσης factor = 0,5 και patience = 3 εποχών).

F. Εκτίμηση Θερμίδων

Παρουσιάζονται δύο συμπληρωματικές προσεγγίσεις εκτίμησης θερμίδων:

- Μέθοδος A: Σταθμισμένη Εκτίμηση Βάσει Κορυφαίων Προβλέψεων (Top-K Weighted Estimation). Η μέθοδος αυτή αξιοποιεί τις top-K ($K = 3$) πιθανότητες εξόδου (softmax) του ταξινομητή (classifier) σε συνδυασμό με πίνακα θερμιδικής αναφοράς του οργανισμού USDA [13]. Για κάθε εικόνα, υπολογίζεται ο σταθμισμένος μέσος όρος (weighted average) των θερμίδων αναφοράς:

$$\text{kcal_est} = \sum_{i=1}^K \hat{p}_i \times \text{kcal_typical}(\text{class_i}) \quad (\text{Εξ. 2})$$

όπου $\hat{p}_i$ είναι οι κανονικοποιημένες πιθανότητες των top-K predictions (ώστε να αθροίζουν σε 1) και kcal_typical η τυπική θερμιδική αξία της κάθε κατηγορίας ανά 100g φαγητού. Η συγκεκριμένη μέθοδος παρέχει το πλεονέκτημα της βαθμονομημένης αβεβαιότητας (calibrated uncertainty), δηλαδή όταν το μοντέλο εμφανίζει υψηλή βεβαιότητα (π.χ. 95% top-1 probability), η τελική εκτίμηση ταυτίζεται ουσιαστικά με τη κορυφαία τιμή, αλλά σε περιπτώσεις αβεβαιότητας ενσωματώνεται αναλογικά η πληροφορία και από εναλλακτικές κατηγορίες, παράγοντας ένα διάστημα εμπιστοσύνης (confidence interval) $[\text{kcal_min}, \text{kcal_max}]$.

- Μέθοδος B: Γεωμετρική Εκτίμηση. Η μέθοδος βασίζεται στην προσέγγιση των Pouladzadeh et al. [1] και υπολογίζει τις θερμίδες μεταφράζοντας τις διαστάσεις των pixel της εικόνας σε φυσικές διαστάσεις. Συγκεκριμένα, χρησιμοποιείται ένα αντικείμενο αναφοράς (reference object) (νόμισμα 2€ διαμέτρου 25,75mm, $\text{area} = \pi \times (25,75/2)^2 \text{ mm}^2 \approx 5,21 \text{ cm}^2$) για τη μετατροπή pixel σε cm. Με τη βοήθεια του reference, υπολογίζονται οι πραγματικές διαστάσεις του φαγητού και στη συνέχεια ο όγκος, το βάρος και οι θερμίδες:

$$V = S \times H \times \beta, \quad W = V \times \rho, \quad \text{kcal} = W \times c \quad (\text{Εξ. 3})$$

όπου V ο όγκος (cm^3), S η επιφάνεια (cm^2), H το ύψος (cm), β ένας συντελεστής σχήματος (shape factor) (πόσο του bounding box είναι όντως φαγητό, εύρος 0,5–1,0 ανά κατηγορία), ρ η πυκνότητα (g/cm^3) και c η θερμιδική πυκνότητα της κατηγορίας (kcal/g). Οι παράμετροι ρ , β , c έχουν προ-καθοριστεί


ανά κατηγορία βάσει βιβλιογραφικών δεδομένων και του USDA. Η μέθοδος αυτή παρέχει εκτίμηση μερίδας με ακρίβεια επιπέδου γραμμαρίου (gram-level), ωστόσο προϋποθέτει αυξημένη προεπεξεργασία (όπως κατάτμηση εικόνας και εκτίμηση ύψους), καθώς και την υποχρεωτική παρουσία του αντικειμένου αναφοράς στο κάδρο.

III. ΑΠΟΤΕΛΕΣΜΑΤΑ

A. Σύνολο Δεδομένων


Για τη διεξαγωγή των πειραμάτων χρησιμοποιήθηκε το σύνολο δεδομένων Food-11 [4], το οποίο αποτελείται συνολικά από 16.643 εικόνες τροφίμων, καταναμημένες σε 11 διακριτές κατηγορίες: Bread, Dairy product, Dessert, Egg, Fried food, Meat, Noodles/Pasta, Rice, Seafood, Soup και Vegetable/Fruit. Η συλλογή του υλικού προέρχεται από τη συνένωση υφιστάμενων συνόλων δεδομένων (Food-101, UEC-Food-100, UEC-Food-256), καθώς και από πλατφόρμες κοινωνικής δικτύωσης και λήψεις μέσω φορητών συσκευών.

Ο προκαθορισμένος διαχωρισμός (split) του dataset περιλαμβάνει 9.866 εικόνες για το σύνολο εκπαίδευσης (training set), 3.430 για το σύνολο επικύρωσης (validation set) και 3.347 για το σύνολο δοκιμής (test set), αναλογία που αντιστοιχεί προσεγγιστικά σε 59%, 21% και 20% αντίστοιχα. Όπως έχει ήδη επισημανθεί, στο συγκεκριμένο σύνολο δεδομένων παρατηρείται έντονη ανισορροπία μεταξύ των κλάσεων. Ειδικότερα, η κατηγορία Rice αποτελεί τη μειονοτική κλάση με μόλις 280 δείγματα εκπαίδευσης, ενώ οι κατηγορίες Dessert και Soup συνιστούν τις πολυπληθέστερες, αριθμώντας από 1.500 δείγματα έκαστη. Η αναλυτική κατανομή των δειγμάτων ανά κλάση και υποσύνολο διαχωρισμού απεικονίζεται στην Εικόνα 1.



Εικόνα 1. Κατανομή δειγμάτων ανά κλάση και split του Food-11 dataset.

Η Εικόνα 2 παρουσιάζει αντιπροσωπευτικά δείγματα εικόνων από κάθε κατηγορία, αναδεικνύοντας την οπτική ποικιλομορφία εντός κάθε κατηγορίας καθώς και τις οπτικές ομοιότητες μεταξύ ορισμένων κατηγοριών (π.χ. Bread/Fried food, Dessert/Dairy product).



Εικόνα 2. Δείγματα εικόνων από κάθε κατηγορία του Food-11.

B. Πειραματικός Σχεδιασμός

Η διεξαγωγή των πειραμάτων πραγματοποιήθηκε σε υπολογιστικό περιβάλλον Google Colab, με την υποστήριξη κάρτας γραφικών NVIDIA T4 και τη χρήση της βιβλιοθήκης PyTorch (έκδοση 2.x). Για την εκπαίδευση των μοντέλων ορίστηκε μέγεθος δέσμης (batch size) ίσο με 64, ενώ για τη διασφάλιση της πλήρους αναπαραγωγικότητας των αποτελεσμάτων (reproducibility) εφαρμόστηκε σταθερή τιμή αρχικοποίησης (seed = 42). Η επιλογή των βέλτιστων υπερπαραμέτρων (hyperparameter tuning) βασίστηκε αποκλειστικά στο σύνολο επικύρωσης (validation set). Αντίθετα, όλες οι τελικές μετρικές απόδοσης εξήχθησαν από το σύνολο δοκιμής (test set), το οποίο διατηρήθηκε αυστηρά αμέτοχο καθ' όλη τη διάρκεια της εκπαίδευσης και της επιλογής των μοντέλων. Ο διαχωρισμός αυτός κρίνεται επιβεβλημένος προκειμένου να αποτραπεί ενδεχόμενη διαρροή πληροφορίας (information leakage) και να παραχθούν αξιόπιστες εκτιμήσεις ως προς την ικανότητα γενίκευσης του συστήματος.

Ως βασικές μετρικές αξιολόγησης επιλέχθηκαν η συνολική ακρίβεια (accuracy) και το μακρο-σταθμισμένο (macro-averaged) F1-score. Η επιλογή του macro F1-score κρίθηκε καταλληλότερη, καθώς αποδίδει ισότιμη βαρύτητα σε όλες τις κλάσεις ανεξάρτητα από το μέγεθός τους, σε αντίθεση με το σταθμισμένο (weighted) F1-score που τείνει να ευνοεί τις πλειονοτικές κατηγορίες, γεγονός που το καθιστά ιδανικό για σύνολα δεδομένων με έντονη ανισορροπία, όπως το Food-11. Συμπληρωματικά, για την πληρέστερη ανάλυση της απόδοσης του εκάστοτε δικτύου, υπολογίζονται και παρατίθενται οι επιμέρους μετρικές ακρίβειας (precision), ανάκλησης (recall) και F1-score ανά κατηγορία (per-class).

C. Συγκριτικά Αποτελέσματα Μοντέλων

Ο Πίνακας 1 παρουσιάζει τη συγκριτική απόδοση των τεσσάρων μοντέλων στο test set του Food-11. Η αρχιτεκτονική ResNet50, με την εφαρμογή της μεθοδολογίας μεταφοράς μάθησης δύο φάσεων (2-phase transfer learning), κατέγραψε την υψηλότερη επίδοση, επιτυγχάνοντας ακρίβεια 90,29% και macro F1-score ίσο με 0,907, υπερέχοντας του μοντέλου βάσης (Custom CNN baseline) κατά 27,58 ποσοστιαίες μονάδες. Η σημαντική αυτή απόκλιση επιβεβαιώνει την αποτελεσματικότητα της προσέγγισης transfer learning έναντι της εκπαίδευσης από το μηδέν


(training from scratch), ιδιαίτερα σε σύνολα δεδομένων αντίστοιχης κλίμακας όπως το Food-11.

Πίνακας 1. Συγκριτική απόδοση μοντέλων στο test set του Food-11 (διατεταγμένα κατά φθίνουσα Test Accuracy).


Μοντέλο	Params (M)	Val Acc	Test Acc	Test F1	Test Loss
ResNet50	23,53	0,8854	0,9029	0,9067	0,288
EfficientNet-B0	4,02	0,8455	0,8629	0,8644	0,431
MobileNetV2	2,24	0,8152	0,8375	0,8329	0,492
CustomCNN	1,21	0,6178	0,6271	0,6370	1,035

Ιδιαίτερο ενδιαφέρον παρουσιάζει η συμβιβαστική σχέση (trade-off) μεταξύ της ακρίβειας και του μεγέθους του εκάστοτε μοντέλου. Το MobileNetV2, παρά το γεγονός ότι ενσωματώνει δέκα φορές λιγότερες παραμέτρους συγκριτικά με το ResNet50, επιτυγχάνει ακρίβεια 83,75%, σημειώνοντας υστέρηση μόλις 6,5 ποσοστιαίων μονάδων. Η επίδοση αυτή καθιστά το συγκεκριμένο δίκτυο μια απολύτως βιώσιμη επιλογή για εφαρμογή σε φορητές συσκευές (mobile deployment), όπου το μέγεθος του μοντέλου και ο χρόνος εξαγωγής συμπεράσματος (inference time) είναι καθοριστικοί παράγοντες. Παράλληλα, το EfficientNet-B0, με περίπου 4M παραμέτρους, καταγράφει ακρίβεια 86,29%, επιβεβαιώνοντας την αποτελεσματικότητα του σχεδιασμού που βασίζεται σε αυτοματοποιημένη αναζήτηση αρχιτεκτονικής (NAS-based design).

Στην Εικόνα 3 αποτυπώνεται η οπτική σύγκριση της ακρίβειας δοκιμής (test accuracy) και του macro F1-score για τα τέσσερα υπό εξέταση μοντέλα, ενώ στην Εικόνα 4 απεικονίζεται η συσχέτιση της ακρίβειας με το πλήθος των παραμέτρων σε λογαριθμική κλίμακα. Από τη συγκεκριμένη γραφική παράσταση φαίνεται καθαρά το όριο αποδοτικότητας (efficiency frontier): το MobileNetV2 προσφέρει τον βέλτιστο συνδυασμό απόδοσης και οικονομίας υπολογιστικών πόρων, ενώ το ResNet50 εξασφαλίζει τη μέγιστη δυνατή ακρίβεια όταν δεν υφίστανται περιορισμοί στα διαθέσιμα υπολογιστικά συστήματα.



Εικόνα 3. Σύγκριση test accuracy και macro F1 των τεσσάρων μοντέλων.




Εικόνα 4. Trade-off μεταξύ test accuracy και αριθμού παραμέτρων (λογαριθμική κλίμακα).

Το όριο αποδοτικότητας (efficiency frontier) είναι σαφές: ο περιορισμός του πλήθους των παραμέτρων συνεπάγεται μεν αναπόφευκτη πτώση της ακρίβειας, προσφέρει ωστόσο ένα ξεκάθαρο οριακό όφελος (marginal benefit) ως προς την εξοικονόμηση πόρων.

D. Ανάλυση ανά Κατηγορία

Στην Εικόνα 5 απεικονίζεται ο θερμικός χάρτης (heatmap) των τιμών F1-score ανά κατηγορία για κάθε εξεταζόμενο μοντέλο, παρέχοντας τη δυνατότητα άμεσης οπτικής σύγκρισης της απόδοσής τους. Όπως παρατηρείται, το προσαρμοσμένο μοντέλο βάσης (Custom CNN baseline) υστερεί σημαντικά στις κατηγορίες Dessert (F1 = 0,283), Bread (0,462), Egg (0,465) και Dairy product (0,462). Η χαμηλή αυτή επίδοση αποδίδεται, κατά πάσα πιθανότητα, στις έντονες οπτικές ομοιότητες που υφίστανται μεταξύ των εν λόγω κλάσεων (όπως για παράδειγμα, η οπτική σύγκυση μεταξύ ενός σάντουιτς με αυγό και ψωμί, ή ενός επιδορπίου με βάση τα γαλακτοκομικά). Επιπλέον, καθοριστικό ρόλο διαδραματίζει η περιορισμένη ικανότητα εξαγωγής πολύπλοκων χαρακτηριστικών (feature extraction) από ένα δίκτυο το οποίο εκπαιδεύεται εξ ολοκλήρου από το μηδέν (from scratch), έχοντας στη διάθεσή του ένα σχετικά μικρό δείγμα της τάξης των 10.000 εικόνων.




Εικόνα 5. Heatmap των F1-scores ανά κατηγορία για τα τέσσερα μοντέλα.

Αντίθετα, το μοντέλο ResNet50 επιτυγχάνει σχεδόν άριστη αναγνώριση στις κατηγορίες που διαθέτουν διακριτή οπτική υπογραφή, όπως οι κλάσεις Soup (F1 = 0,968), Vegetable-Fruit (F1 = 0,972) και Noodles-Pasta (F1 = 0,945). Επιπλέον, καταγράφεται θεαματική βελτίωση στις "δύσκολες" κατηγορίες, με χαρακτηριστικότερο παράδειγμα την κλάση Dessert, η οποία σημειώνει F1-score 0,859 (αύξηση της τάξης των +57,6 ποσοστιαίων μονάδων

συγκριτικά με το μοντέλο βάσης). Αξιοσημείωτη κρίνεται, επίσης, η επίδοση του ResNet50 στην πλέον μειονοτική κατηγορία Rice (η οποία διέθετε μόλις 280 δείγματα εκπαίδευσης), επιτυγχάνοντας F1-score ίσο με 0,945. Το γεγονός αυτό αποτελεί ισχυρή ένδειξη της αποτελεσματικότητας της σταθμισμένης συνάρτησης κόστους ως προς την εξομάλυνση της ανισορροπίας του συνόλου δεδομένων.

Η Εικόνα 6 παρουσιάζει τους πίνακες σύγκυσης (confusion matrices) των τεσσάρων μοντέλων σε διάταξη 2×2. Η τοποθέτησή τους έχει γίνει με σειρά αυξανουσας απόδοσης, ξεκινώντας από το λιγότερο ακριβές (CustomCNN, άνω αριστερά) και καταλήγοντας στο βέλτιστο (ResNet50, κάτω δεξιά). Μέσω της οπτικής αυτής αντιπαράβολής, καθίσταται εμφανής η σταδιακή βελτίωση της προβλεπτικής ικανότητας: η μετάβαση σε ισχυρότερες αρχιτεκτονικές αποτυπώνεται με την αυξανόμενη πυκνωση της κύριας διαγωνίου του πίνακα, γεγονός που μεταφράζεται σε αισθητή μείωση των εσφαλμένων ταξινομήσεων (misclassifications). Ενδεικτικά αναφέρεται ότι τα συστηματικά σφάλματα που παρατηρούνται στο CustomCNN, όπως η λανθασμένη κατηγοριοποίηση της κλάσης Bread ως Fried food (ποσοστό 20%) και της κλάσης Egg ως Bread (ποσοστό 15%), εξαλείφονται σχεδόν ολοκληρωτικά στο μοντέλο ResNet50.



Εικόνα 6. Combined normalized confusion matrices των τεσσάρων μοντέλων. Από το χειρότερο (πάνω-αριστερά: CustomCNN, acc=0,627) στο καλύτερο (κάτω-δεξιά: ResNet50, acc=0,903).

E. Σύγκριση με Βιβλιογραφία

Ο Πίνακας 2 παρουσιάζει σύγκριση της παρούσας μεθόδου με τις βασικές εργασίες στη βιβλιογραφία που έχουν αξιολογηθεί στο Food-11 dataset.

Εργασία	Μέθοδος	Accuracy
Singla et al. [4]	GoogLeNet + Transfer Learning	83,60%
Sarac & Ozyilmaz [5]	AlexNet+VGG features + SVM	88,08%

Yang [6]	ResNet50 + Transfer Learning	~88-90%
Παρούσα Εργασία	ResNet50 + 2-phase Transfer Learning	90,29%


Πίνακας 2. Σύγκριση με αντίστοιχες εργασίες στη βιβλιογραφία στο Food-11.

Η προτεινόμενη μεθοδολογία ξεπερνά σημαντικά την εργασία αναφοράς των Singla et al. [4] (90,29% vs 83,60%, διαφορά +6,69 ποσοστιαίων μονάδων) και είναι ανταγωνιστική με την εργασία των Sarac & Ozyilmaz [5] (90,29% vs 88,08%, +2,21 pp). Η βελτίωση αυτή μπορεί να αποδοθεί στους εξής παράγοντες:

- (i) Χρήση νεότερου και ισχυρότερου δικτύου κορμού (backbone) (ResNet50 με βάρη V2 αντί του δικτύου GoogLeNet που είναι ασθενέστερο). Το επιλεγμένο μοντέλο έχει εκπαιδευτεί εκ των προτέρων με αναβαθμισμένα πρωτόκολλα εκπαίδευσης (training recipes).
 - (ii) Η στρατηγική μικρορύθμισης δύο φάσεων (2-phase fine-tuning) που αποτρέπει αποτελεσματικά την εμφάνιση του φαινομένου της καταστροφικής λήθης (catastrophic forgetting), επιτρέποντας παράλληλα την ομαλή και σταδιακή προσαρμογή των εξαγόμενων χαρακτηριστικών του ImageNet στο εξειδικευμένο πεδίο των τροφίμων.
 - (iii) Η χρήση σταθμισμένης συνάρτησης κόστους (weighted loss) για την αντιμετώπιση της ανισορροπίας των κλάσεων (imbalance), επιφέροντας αισθητή αναβάθμιση στην απόδοση των μειονοτικών κατηγοριών, όπως αποδεικνύεται από την υψηλή τιμή F1-score (0,955) που επιτεύχθηκε στην κλάση Rice.
 - (iv) Οι σύγχρονες τεχνικές επαύξησης δεδομένων (data augmentation) στις οποίες έχουν επιλεγεί εξειδικευμένοι μετασχηματισμοί, προσαρμοσμένοι στις οπτικές ιδιαιτερότητες των φωτογραφιών πιάτων (όπως οι RandomResizedCrop και ColorJitter), ενισχύοντας σημαντικά τη γενικευτική ικανότητα των δικτύων.
- Συνολικά, η προτεινόμενη μεθοδολογία αποδίδει εντυπωσιακά αποτελέσματα στο συγκεκριμένο dataset.

F. Αξιολόγηση Εκτίμησης Θερμίδων

Η Μέθοδος A (σταθμισμένη εκτίμηση βάσει κορυφαίων προβλέψεων - top-K weighted estimation) αξιολογήθηκε σε ένα αντιπροσωπευτικό δείγμα 11 εικόνων προερχόμενο από το σύνολο δοκιμής (test set), το οποίο περιελάμβανε ακριβώς μία εικόνα από κάθε διαθέσιμη κατηγορία (Εικόνα 7). Κατά τη διαδικασία αυτή, επιτεύχθηκε η απόλυτα ορθή ταξινόμηση και των 11 εικόνων του δείγματος από το σύστημα. Παράλληλα, για κάθε μεμονωμένη εικόνα εξήχθη μια εκτίμηση της θερμιδικής της αξίας (εκφρασμένη σε kcal ανά 100g), η οποία πλαισιώθηκε από το αντίστοιχο διάστημα εμπιστοσύνης (confidence interval) της μορφής [kcal_min, kcal_max].



Εικόνα 7. Demo εκτίμησης θερμίδων με τη Μέθοδο A (top-K weighted) σε δείγμα 11 εικόνων test set, μία ανά κατηγορία. Πάνω από κάθε εικόνα εμφανίζεται η πραγματική και προβλεπόμενη κλάση, το confidence του μοντέλου και η εκτιμώμενη θερμιδική αξία με εύρος.

Σε περιπτώσεις υψηλής εμπιστοσύνης (όπου η πιθανότητα της επικρατέστερης κλάσης υπερβαίνει το 95%), η εξαγόμενη εκτίμηση προσεγγίζει την τυπική θερμιδική τιμή της εκάστοτε κατηγορίας. Αντιθέτως, σε περιπτώσεις μειωμένης βεβαιότητας, όπως συμβαίνει συχνά στην κατηγορία Dessert λόγω της τεράστιας οπτικής της ποικιλομορφίας (π.χ. μπισκότα, κέικ, παγωτό, μακαρόν), το δίκτυο κατανέμει τις πιθανότητες. Για παράδειγμα, μπορεί να αποδώσει 71% στην κλάση Dessert, 11% στη Fried food και 9% στην Bread. Σε αυτή την περίπτωση, η σταθμισμένη εκτίμηση διαμορφώνεται στις 337 kcal ανά 100g, συνοδευόμενη από ένα εύρος τιμών [249, 486], το οποίο αντικατοπτρίζει πιστά την αβεβαιότητα της πρόβλεψης. Η προσέγγιση αυτή πλεονεκτεί σημαντικά έναντι της απλής επιλογής της επικρατέστερης κλάσης (top-1 prediction), καθώς προσφέρει βαθμονομημένη αβεβαιότητα (calibrated uncertainty), ιδανική για αξιοποίηση σε μεταγενέστερες εφαρμογές (downstream applications).

Από την άλλη πλευρά, η Μέθοδος B (γεωμετρική προσέγγιση) παρέχει τη δυνατότητα εκτίμησης της μερίδας με ακρίβεια επιπέδου γραμμαρίου, εφόσον υφίσταται διαθέσιμο αντικείμενο αναφοράς (reference object, όπως π.χ. ένα νόμισμα των 2€). Ενδεικτικά, για ένα δείγμα κρέατος στο οποίο το αντικείμενο αναφοράς καταλαμβάνει επιφάνεια 2.000 pixels², ενώ η επιφάνεια του τροφίμου ανέρχεται σε 35.000 pixels² με εκτιμώμενο ύψος τα 150 pixels, ο υπολογισμός αποδίδει όγκο της τάξης των 22 cm³, βάρος περίπου 23g και συνολική θερμιδική αξία 58 kcal για τη συγκεκριμένη μερίδα. Η μέθοδος αυτή κρίνεται κατάλληλότερη για επαγγελματικές εφαρμογές στον τομέα της διατροφολογίας, ωστόσο προϋποθέτει ακριβή κατάτμηση της εικόνας (image segmentation) και παρουσία του αντικείμενου αναφοράς στο κάδρο.

Συνολικά, οι δύο μέθοδοι είναι συμπληρωματικές: η Μέθοδος A είναι κατάλληλη για real-world εφαρμογές χωρίς controlled setup, ενώ η Μέθοδος B για επαγγελματικά πλαίσια με reference object και segmentation pipeline.

Πέραν της αξιολόγησης στο test set, το βέλτιστο μοντέλο (ResNet50) ενσωματώθηκε σε ένα διαδραστικό υποσύστημα όπου ο χρήστης μπορεί να ανεβάσει αυθαίρετες εικόνες φαγητού και να λάβει σε πραγματικό χρόνο την πρόβλεψη κατηγορίας, τις top-3 εναλλακτικές με τα αντίστοιχα confidence scores, και την εκτίμηση θερμίδων (Μέθοδος A). Το υποσύστημα αυτό επιδεικνύει την πρακτική

εφαρμοσιμότητα του προτεινόμενου μοντέλου σε ρεαλιστικές συνθήκες, εκτός του ελεγχόμενου περιβάλλοντος του dataset.

IV. ΣΥΜΠΕΡΑΣΜΑΤΑ

Στην παρούσα εργασία πραγματοποιήθηκε εκτεταμένη συγκριτική μελέτη τεσσάρων αρχιτεκτονικών CNN για την αναγνώριση εικόνων φαγητού στο Food-11 dataset, σε συνδυασμό με δύο συμπληρωματικές μεθόδους εκτίμησης θερμίδων. Τα κύρια ευρήματα συνοψίζονται ως εξής:

(α) Η μεθοδολογία μεταφοράς μάθησης δύο φάσεων (two-phase transfer learning) πλεονεκτεί συντριπτικά έναντι της εκπαίδευσης από το μηδέν (training from scratch). Ειδικότερα, η αρχιτεκτονική ResNet50 επιτυγχάνει ακρίβεια δοκιμής (test accuracy) 90,29% έναντι 62,71% του μοντέλου βάσης, σημειώνοντας βελτίωση της τάξης των 27,58 ποσοστιαίων μονάδων. Το γεγονός αυτό επιβεβαιώνει πως, σε σύνολα δεδομένων περιορισμένης κλίμακας όπως το Food-11, η αξιοποίηση προεκπαιδευμένων χαρακτηριστικών (pretrained features) καθίσταται απολύτως αναγκαία.

(β) Διαπιστώνεται μια σαφής συμβιβαστική σχέση (trade-off) μεταξύ της προβλεπτικής ακρίβειας και του μεγέθους των μοντέλων. Το MobileNetV2, ενσωματώνοντας δέκα φορές λιγότερες παραμέτρους συγκριτικά με το ResNet50, διατηρεί εξαιρετικά ανταγωνιστική απόδοση (83,75%). Το χαρακτηριστικό αυτό το καθιστά ιδανικό για ενσωμάτωση σε φορητές συσκευές (mobile deployment), όπου οι περιορισμοί μεγέθους, διαθέσιμης μνήμης και χρόνου εξαγωγής συμπεράσματος (inference time) είναι κρίσιμοι.

(γ) Η εφαρμογή της σταθμισμένης συνάρτησης κόστους (weighted loss) αντιμετώπισε με επιτυχία το πρόβλημα της ανισορροπίας των κλάσεων. Ενδεικτικά, η κατηγορία Rice, ούσα η μικρότερη με μόλις 280 δείγματα εκπαίδευσης, κατέγραψε F1-score 0,955 (με το μοντέλο ResNet50), ξεπερνώντας σε απόδοση πολλές πολυπληθέστερες κατηγορίες.

(δ) Η Dessert κατηγορία, που είναι ιδιαίτερα δύσκολη λόγω υψηλής οπτικής ποικιλομορφίας, παρουσίασε θεαματική βελτίωση από $F1 = 0,283$ (CustomCNN) σε $F1 = 0,846$ (ResNet50), αναδεικνύοντας τη σημασία της επιλογής ισχυρότερων αρχιτεκτονικών για δύσκολες κλάσεις.

(ε) Οι δύο προτεινόμενες προσεγγίσεις για την εκτίμηση των θερμίδων λειτουργούν συμπληρωματικά. Η σταθμισμένη μέθοδος κορυφαίων προβλέψεων (top-K weighted) χαρακτηρίζεται από ταχύτητα και απλότητα, προσφέροντας παράλληλα βαθμονομημένη αβεβαιότητα (calibrated uncertainty). Αντίθετα, η γεωμετρική προσέγγιση εξασφαλίζει εκτίμηση της μερίδας με ακρίβεια επιπέδου γραμμαρίου (gram-level), προϋποθέτει ωστόσο την παρουσία αντικειμένου αναφοράς (reference object) και την εφαρμογή κατάταξης εικόνας (image segmentation).

(στ) Η σύγκριση με τη βιβλιογραφία δείχνει ότι η προτεινόμενη μεθοδολογία επιτυγχάνει σημαντικά αποτελέσματα στο Food-11 (90,29% vs 83,60% του Singla et al. [4] και 88,08% του Sarac & Ozyilmaz [5]).

A. Περιορισμοί

Παρά τα θετικά αποτελέσματα, η μελέτη παρουσιάζει ορισμένους περιορισμούς:

- Το μοντέλο EfficientNet-B0 ενδέχεται να μην έφτασε σε πλήρη σύγκλιση (convergence) κατά τη

διάρκεια των 10 εποχών εκπαίδευσης (5+5). Η ανάλυση των καμπυλών εκπαίδευσης υποδηλώνει ότι μια πιο παρατεταμένη εκπαίδευση θα μπορούσε να οδηγήσει σε ακρίβεια της τάξης του 87-88%.

- Η γεωμετρική μέθοδος εκτίμησης θερμίδων βασίζεται σε παραδοχές ως προς το σχήμα (μέσω του συντελεστή β), οι οποίες είναι ιδιαίτερα ευαίσθητες στη γωνία λήψης (camera angle) και την οπτική προοπτική της εκάστοτε φωτογραφίας.
- Το σύνολο δεδομένων Food-11 θεωρείται συγκριτικά μικρό (περίπου 16.000 εικόνες). Η αξιολόγηση σε ευρύτερα σύνολα δεδομένων θα προσέδιδε μεγαλύτερη στατιστική αξιοπιστία στα εξαγόμενα συμπεράσματα.
- Δεν αξιολογήθηκε ποσοτικά η ακρίβεια της εκτίμησης θερμίδων (kcal mean absolute error), καθώς το Food-11 δεν παρέχει ενσωματωμένα δεδομένα αναφοράς (ground truth) για τη θερμιδική αξία των πιάτων.

B. Μελλοντικές Προοπτικές

Μελλοντικές ερευνητικές κατευθύνσεις περιλαμβάνουν:

- Την επέκταση της μελέτης σε μεγαλύτερα και πιο σύνθετα σύνολα δεδομένων, όπως το Food-101 (101 κατηγορίες, 101.000 εικόνες) ή το A14Food-NutritionDB [8] (558.000 εικόνες με διατροφική ταξινόμηση πέντε επιπέδων), προκειμένου να επαληθευτεί περαιτέρω η ικανότητα γενίκευσης της προτεινόμενης μεθοδολογίας.
- Την ενσωμάτωση τεχνικών κατάταξης εικόνας (image segmentation), όπως τα δίκτυα Mask R-CNN ή U-Net, με στόχο την αυτοματοποιημένη εκτίμηση της μερίδας χωρίς τη χρήση αντικειμένου αναφοράς. Αυτό δύναται να επιτευχθεί μέσω της έξυπνης αξιοποίησης οπτικών ενδείξεων του περιβάλλοντος (context cues), όπως η διάμετρος των πιάτων ή το μέγεθος των μαχαιροπίρουνων.
- Τη συγκριτική αξιολόγηση με σύγχρονες αρχιτεκτονικές Οπτικών Μετασχηματιστών (Vision Transformers - ViT), οι οποίες επιδεικνύουν ραγδαία εξέλιξη και κορυφαίες επιδόσεις σε πλήθος προβλημάτων ταξινόμησης εικόνων.
- Την πρακτική ενσωμάτωση (integration) του συστήματος σε εφαρμογή για κινητές συσκευές, αξιοποιώντας μια κβαντισμένη έκδοση (quantized) του MobileNetV2 (π.χ. INT8), για την ταχύτατη εκτέλεση προβλέψεων απευθείας στη συσκευή (on-device inference) σε λειτουργικά συστήματα iOS και Android.

V. ΒΙΒΛΙΟΓΡΑΦΙΑ

- [1] P. Pouladzadeh, S. Shirmohammadi, and R. Almaghrabi, "Measuring Calorie and Nutrition From Food Image," IEEE Transactions on Instrumentation and Measurement, vol. 63, no. 8, pp. 1947–1956, Aug. 2014.
- [2] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," in Proceedings of the International Conference on Learning Representations (ICLR), 2015.

- [3] S. Mezgec and B. Koroušić Seljak, "NutriNet: A Deep Learning Food and Drink Image Recognition System for Dietary Assessment," *Nutrients*, vol. 9, no. 7, p. 657, 2017.
- [4] A. Singla, L. Yuan, and T. Ebrahimi, "Food/Non-food Image Classification and Food Categorization using Pre-Trained GoogLeNet Model," in *Proceedings of the 2nd International Workshop on Multimedia Assisted Dietary Management (MADiMa)*, ACM Multimedia, 2016, pp. 3–11.
- [5] B. Sarac and L. Ozyilmaz, "Food Image Classification with Deep Features," in *Proceedings of the International Conference on Artificial Intelligence and Data Processing (IDAP)*, IEEE, 2019, pp. 1–6.
- [6] L. Yang, "Recognition of food images based on transfer learning and ensemble learning," *PLOS ONE*, vol. 19, no. 1, e0296789, 2024.
- [7] Y. Zhou, X. Min, S. Jiang, Y. Wang, Z. Liu, S. Yu, X. Liu, S. Mei, and S. Wang, "Deep learning in food category recognition," *Information Fusion*, vol. 98, p. 101859, 2023.
- [8] S. Rodríguez, R. Tolosana, R. Vera-Rodríguez, J. Fierrez, and J. Ortega-García, "Leveraging Automatic Personalised Nutrition: Food Image Recognition Benchmark and Dataset based on Nutrition Taxonomy," *arXiv:2211.07440*, 2024.
- [9] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [10] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.
- [11] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR vol. 97, 2019, pp. 6105–6114.
- [12] U.S. Department of Agriculture, Agricultural Research Service, "FoodData Central," 2024. [Online]. Available: <https://fdc.nal.usda.gov/>